

Campamento 4:

El Glaciar de la

Inteligencia

Ruta extendida de Quantum Machine Learning (QML)

Principios del Glaciar

- Entender primero el modelo mental; automatizar después con librerías.
- Construir cada concepto junto a un experimento reproducible en Git.
- Comparar modelos cuánticos con referencias clásicas cuando tenga sentido.
- Tratar el ruido, la medición y el hardware como preguntas experimentales; volver al Laboratorio cuando sea necesario.
- Permitir que el repositorio conserve intentos, errores y cambios de comprensión como evidencia de evolución.
- Cerrar el campamento con una pregunta propia, no únicamente con una colección de tutoriales completados.

Mapa general del campamento

Misión	Núcleo	Función en la ruta
0	¿Dónde está lo cuántico en Machine Learning?	Modelo mental y fundamentos de aprendizaje.
1	Datos clásicos dentro de un sistema cuántico	Codificación de datos y Quantum Feature Maps.
2	Espacios de características y Quantum Kernels	Similitud, fidelidad y clasificación basada en kernels.
3	Circuitos que pueden aprender	Circuitos parametrizados, ansatz y observables.
4	¿Cómo aprende un circuito cuántico?	Pérdida, optimización, gradientes y entrenamiento híbrido.
5	Variational Quantum Classifiers	Construcción y comprensión integral de un VQC.
6	Cuando entrenar deja de ser fácil	Expresividad, escalabilidad, barren plateaus y ruido.
7	PennyLane y modelos híbridos	Integración del circuito con herramientas clásicas de ML.
8	El zoológico de QML	Exploración de familias y arquitecturas del campo.
9	¿Esto sirve realmente?	Evaluación crítica y comparación con baselines clásicos.
10	Expedición propia	Proyecto propio nacido del campamento.

Misión 0 – ¿Dónde está lo cuántico en Machine Learning?

Construir el modelo mental del campo antes de utilizar herramientas específicas. La misión conecta el ciclo básico de aprendizaje automático con la forma en que un circuito cuántico puede participar en representación, inferencia u optimización.

Preguntas guía. ¿Qué significa que un modelo “aprenda”? ¿Qué partes de un flujo QML siguen siendo clásicas? ¿Qué papel juega el computador cuántico? ¿Qué tendría que ocurrir para hablar de una ventaja cuántica real?

Núcleo técnico. Datos, parámetros, predicción, función de pérdida, entrenamiento, validación, generalización y arquitectura híbrida cuántico-clásica.

Proyecto Git. Crear el repositorio y un primer cuaderno de fundamentos donde se dibuje el flujo datos $\rightarrow$ modelo $\rightarrow$ predicción $\rightarrow$ error $\rightarrow$ actualización, identificando qué componente podría ser cuántico.

Hito de salida. Poder explicar un sistema QML completo sin depender todavía de nombres de librerías o clases preconstruidas.

Misión 1 – Datos clásicos dentro de un sistema cuántico

Estudiar cómo una entrada clásica se convierte en una representación cuántica. La misión original de Quantum Feature Maps se expande para comprender que la codificación no es un trámite: condiciona qué información puede expresar y distinguir el modelo.

Preguntas guía. ¿Cómo termina un vector clásico dentro de qubits? ¿Qué información conserva cada estrategia? ¿Qué coste tiene la codificación? ¿Cómo cambia el estado cuando cambia el dato?

Núcleo técnico. Data encoding, feature maps, rotaciones parametrizadas por datos, codificación angular, codificación en amplitud y representación en el espacio de Hilbert.

Proyecto Git. Implementar varias codificaciones pequeñas sobre uno o pocos qubits, visualizar estados o probabilidades y comparar cómo diferentes entradas producen diferentes representaciones.

Hito de salida. Poder elegir y justificar una estrategia de codificación sencilla para un problema concreto.

Misión 2 – Espacios de características y Quantum Kernels

Conectar directamente el espacio de Hilbert con la idea clásica de representar datos en un espacio de características. Se estudia cómo la similitud entre estados cuánticos puede convertirse en una herramienta para clasificación o regresión.

Preguntas guía. ¿Qué significa que dos datos sean “parecidos” después de codificarlos? ¿Por qué un producto interno puede funcionar como medida de similitud? ¿Qué gana o pierde un kernel al usar una representación cuántica?

Núcleo técnico. Feature space, inner product, fidelidad entre estados, kernel matrix y algoritmos de kernel clásicos alimentados por similitudes cuánticas.

Proyecto Git. Construir una matriz de kernel a partir de circuitos pequeños y utilizarla en un clasificador sencillo; después contrastarla con un kernel clásico.

Hito de salida. Entender la conexión datos clásicos $\rightarrow$ estados cuánticos $\rightarrow$ similitud $\rightarrow$ algoritmo de aprendizaje clásico.

Misión 3 – Circuitos que pueden aprender

Introducir los circuitos cuánticos parametrizados como modelos ajustables. Aquí aparece la diferencia entre parámetros que representan datos y parámetros que el entrenamiento puede modificar.

Preguntas guía. ¿Qué puede cambiar realmente al variar θ ? ¿Qué papel cumple la estructura del circuito? ¿Qué significa escoger un ansatz? ¿Cómo se convierte una medición en una salida del modelo?

Núcleo técnico. Parameterized Quantum Circuits (PQC), ansatz, parámetros entrenables, observables, expectation values y profundidad de circuito.

Proyecto Git. Crear un circuito parametrizado mínimo, barrer sus parámetros y visualizar cómo cambia su salida. Conservar versiones ingenuas antes de introducir estructuras más elaboradas.

Hito de salida. Poder mirar un circuito variacional e identificar entrada, parámetros entrenables, observable y salida.

Misión 4 – ¿Cómo aprende un circuito cuántico?

Construir el ciclo de entrenamiento de forma explícita antes de delegarlo a una biblioteca. El objetivo es comprender cómo una predicción cuántica alimenta una función de pérdida y cómo un optimizador clásico actualiza parámetros del circuito.

Preguntas guía. ¿Cómo se calcula el error? ¿Cómo se obtiene información sobre la dirección en la que deben cambiar los parámetros? ¿Por qué el entrenamiento suele ser híbrido?

Núcleo técnico. Loss function, optimización, gradientes, parameter-shift, optimizadores clásicos, número de shots y bucle de entrenamiento.

Proyecto Git. Entrenar manualmente uno o pocos parámetros, registrando pérdida y predicción en cada iteración. Luego repetir el mismo experimento con una herramienta de autodiferenciación.

Hito de salida. Comprender cada paso del ciclo datos $\rightarrow$ circuito $\rightarrow$ medición $\rightarrow$ predicción $\rightarrow$ pérdida $\rightarrow$ actualización de θ .

Misión 5 – Variational Quantum Classifiers (VQC)

Integrar los elementos anteriores en el primer modelo variacional de clasificación. Esta misión conserva el núcleo de la ruta original, pero llega después de haber desmontado las piezas que componen un VQC.

Preguntas guía. ¿Cómo se combinan feature map y ansatz? ¿Cómo se convierte una medición en una clase? ¿Qué parámetros aprende el modelo? ¿Qué cambia cuando aumentan los datos o los qubits?

Núcleo técnico. Clasificación binaria, feature map, ansatz, observables, loss, optimizer, entrenamiento y evaluación.

Proyecto Git. Construir primero un clasificador variacional pequeño de forma explícita y, después, reproducirlo con una implementación de alto nivel para comparar lo que la librería automatiza.

Hito de salida. Ser capaz de explicar y reconstruir conceptualmente un VQC sin tratarlo como una caja negra.

Misión 6 – Cuando entrenar deja de ser fácil

Estudiar los problemas que aparecen cuando un modelo variacional crece o se acerca a condiciones físicas más realistas. El objetivo es evitar que “entrenó” sea sinónimo de “funciona”.

Preguntas guía. ¿Por qué algunos circuitos no aprenden? ¿Qué ocurre cuando los gradientes son diminutos? ¿Cómo afectan profundidad, inicialización, shots y ruido? ¿Qué parte del problema pertenece al algoritmo y cuál al hardware?

Núcleo técnico. Trainability, expresividad, barren plateaus, varianza estadística, profundidad, escalabilidad, ruido y sensibilidad de la optimización.

Proyecto Git. Romper deliberadamente modelos: aumentar profundidad, introducir ruido o cambiar inicializaciones y registrar cuándo y cómo empeora el entrenamiento.

Hito de salida. Reconocer al menos varias causas distintas de un entrenamiento deficiente y diseñar un experimento para aislarlas.

Misión 7 – PennyLane y modelos híbridos

Usar una herramienta especializada solo después de conocer la mecánica que automatiza. La misión original de PennyLane se convierte en el puente hacia flujos híbridos donde circuitos cuánticos participan dentro de un sistema clásico de aprendizaje.

Preguntas guía. ¿Cómo se integra un circuito dentro de un pipeline de ML? ¿Cómo circulan parámetros y gradientes? ¿Qué parte ejecuta el backend cuántico y qué parte permanece en el framework clásico?

Núcleo técnico. QNodes o abstracciones equivalentes, autodiferenciación, capas híbridas, integración con frameworks de Machine Learning y gestión de backends.

Proyecto Git. Reimplementar uno de los experimentos anteriores dentro de PennyLane y construir un modelo híbrido pequeño conectado a una capa o flujo clásico.

Hito de salida. Poder pasar de una implementación manual a una abstracción de alto nivel sin perder la explicación de lo que ocurre debajo.

Misión 8 – El zoológico de QML

Explorar el territorio más allá del VQC para descubrir qué familias despiertan interés y qué problemas intentan resolver. No se busca dominar todas las arquitecturas, sino aprender a reconocerlas y compararlas.

Preguntas guía. ¿Qué diferencia un enfoque variacional de uno basado en kernels? ¿Qué otras arquitecturas existen? ¿Qué ideas se repiten entre ellas? ¿Qué línea del campo merece una exploración más profunda?

Núcleo técnico. Quantum Neural Networks, quantum kernels, modelos variacionales, QCNN, regresión, modelos generativos, autoencoders y otras arquitecturas que resulten relevantes durante el recorrido.

Proyecto Git. Crear pequeñas exploraciones independientes. Cada una debe responder una pregunta concreta y terminar con una nota de qué aporta, qué limita y si merece continuar.

Hito de salida. Identificar una o dos familias de QML que resulten especialmente interesantes y justificar por qué.

Misión 9 – ¿Esto sirve realmente?

Introducir una evaluación crítica permanente. Un modelo cuántico no se considera valioso únicamente porque produzca una métrica alta: debe compararse con alternativas simples y analizar su coste, complejidad y condiciones de uso.

Preguntas guía. ¿Aprende mejor que un baseline clásico? ¿Con cuántos parámetros, muestras y ejecuciones? ¿Qué ocurre al escalar? ¿Dónde aparece el coste real? ¿Qué evidencia sería necesaria para sostener una ventaja?

Núcleo técnico. Baselines, accuracy y otras métricas apropiadas, coste computacional, número de circuit executions/shots, complejidad, escalabilidad y noción de quantum advantage.

Proyecto Git. Acompañar los experimentos importantes con al menos una referencia clásica sencilla. Documentar resultados favorables y desfavorables con la misma importancia.

Hito de salida. Poder defender con evidencia qué aporta —o no aporta— el componente cuántico en un experimento determinado.

Misión 10 – Expedición propia

Cerrar el campamento transformando el aprendizaje acumulado en una pregunta propia. La expedición puede convertirse en un proyecto de portafolio, una investigación exploratoria o la semilla de un trabajo académico posterior.

Preguntas guía. ¿Qué pregunta apareció repetidamente durante el campamento? ¿Qué resultado nos sorprendió? ¿Qué limitación merece ser estudiada? ¿Qué experimento podemos diseñar que ya no sea simplemente reproducción de un tutorial?

Núcleo técnico. Diseño experimental, formulación de hipótesis, selección de métricas, reproducibilidad, comparación y comunicación técnica.

Proyecto Git. Crear una carpeta o repositorio de expedición con objetivo, hipótesis, metodología, experimentos, resultados, limitaciones y conclusiones.

Hito de salida. Terminar el Glaciar con una pregunta nueva y suficientemente concreta como para continuar investigándola por iniciativa propia.